Flink 写 StarRocks 完整数据流转分析¶

> 基于 starrocks-connector-for-apache-flink 源码分析，聚焦 **Exactly-Once** 语义下的 Transaction Stream Load 机制。

目录¶

- 1. 架构总览
- 2. 事务 HTTP API
- 3. 完整数据流转流程
- 阶段 1：数据接收与本地缓存
- 阶段 2：Flush 触发与数据发送
- 阶段 3：Checkpoint 触发（snapshotState）
- 阶段 4：Checkpoint 完成 → Commit
- 阶段 5：异常处理与恢复
- 4. 时序图（Exactly-Once 完整流程）
- 5. V2 Sink API 对比
- 6. 事务生命周期总结
- 7. 常见误区
- 8. 关键代码文件索引

1. 架构总览¶

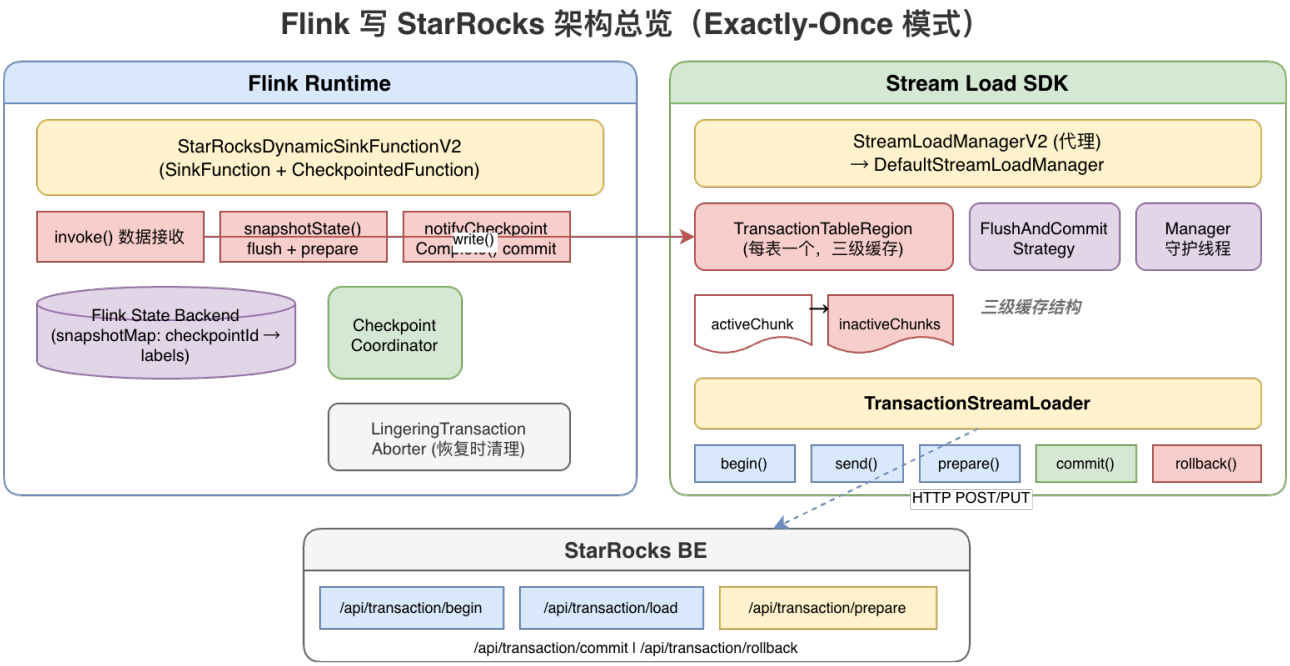

Flink Connector 写入 StarRocks 的核心组件层次如下：

```
StarRocksDynamicSinkFunctionV2        ← Flink SinkFunction + CheckpointedFunction
    │
    ├── invoke()                      ← 数据接收入口
    ├── snapshotState()               ← Checkpoint 时 flush + prepare
    ├── notifyCheckpointComplete()    ← Checkpoint 成功后 commit
    └── close()                       ← 任务关闭时 abort
            │
            ▼
      StreamLoadManagerV2             ← 代理/委托层
            │
            ▼
      DefaultStreamLoadManager        ← 真正实现
            │
            ├── TransactionTableRegion ← 每个表一个，管理三级缓存
            │       ├── activeChunk    ← 正在接收数据的内存块
            │       └── inactiveChunks ← 待发送的 Chunk 队列
            │
            ├── FlushAndCommitStrategy ← flush/commit 决策策略
            │
            ├── Manager 守护线程       ← 周期性扫描，触发 flush/commit
            │
            └── TransactionStreamLoader ← HTTP 事务操作
                    ├── begin()        → /api/transaction/begin
                    ├── send()         → /api/transaction/load
                    ├── prepare()      → /api/transaction/prepare
                    ├── commit()       → /api/transaction/commit
                    └── rollback()     → /api/transaction/rollback
```

```
graph TB
    subgraph Flink Runtime
        A[StarRocksDynamicSinkFunctionV2] --> B[StreamLoadManagerV2]
        A --> S[Flink State Backend]
        A --> CK[Checkpoint Coordinator]
    end

    subgraph Stream Load SDK
        B --> C[DefaultStreamLoadManager]
        C --> D[TransactionTableRegion]
        C --> E[FlushAndCommitStrategy]
        C --> F[Manager 守护线程]
        D --> G[activeChunk]
        D --> H[inactiveChunks]
        C --> I[TransactionStreamLoader]
    end

    subgraph StarRocks BE
        J["/api/transaction/begin"]
        K["/api/transaction/load"]
        L["/api/transaction/prepare"]
        M["/api/transaction/commit"]
        N["/api/transaction/rollback"]
    end

    I --> J
    I --> K
    I --> L
    I --> M
    I --> N
```

---

2. 事务 HTTP API¶

StarRocks 的 Transaction Stream Load 提供以下 HTTP 接口（定义于 `StreamLoadConstants`）：

操作	HTTP 方法	URL	说明
begin	POST	`/api/transaction/begin`	开启一个新事务，绑定 label
send	PUT	`/api/transaction/load`	在已开启的事务内发送数据
prepare	POST	`/api/transaction/prepare`	预提交事务（两阶段提交第一阶段）
commit	POST	`/api/transaction/commit`	正式提交事务，数据可见
rollback	POST	`/api/transaction/rollback`	回滚事务，丢弃数据

每个事务通过唯一的 **label** 标识。在 Exactly-Once 模式下，label 由 `ExactlyOnceLabelGeneratorFactory` 生成，格式可预测（包含 labelPrefix、table、subtaskIndex、checkpointId），便于故障恢复时定位残留事务。

3. 完整数据流转流程¶

Flink Connector 写 StarRocks 完整时序图（Exactly-Once 两阶段提交）

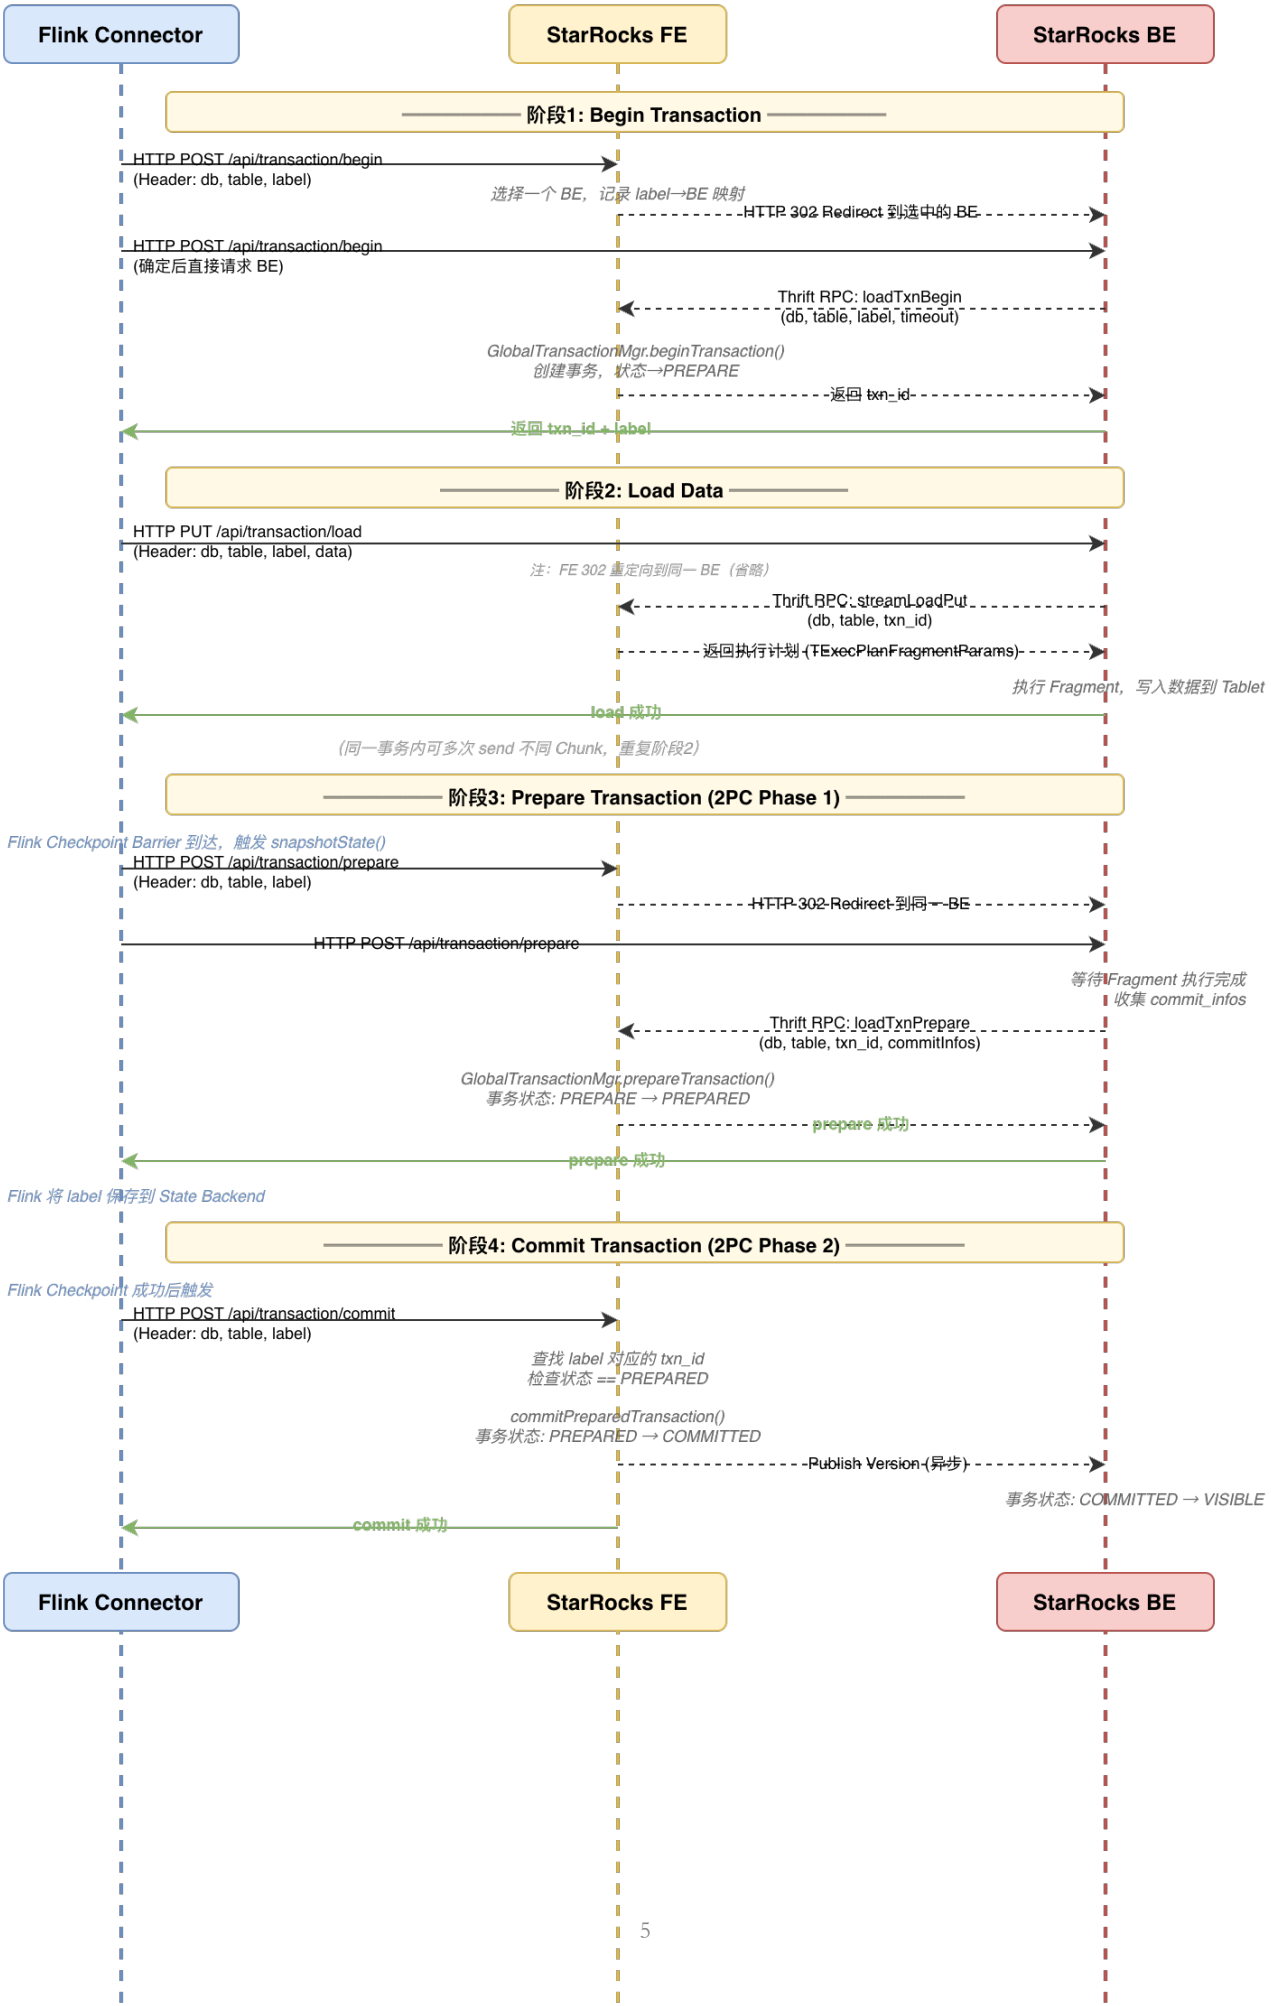

阶段 1：数据接收与本地缓存¶

入口：`StarRocksDynamicSinkFunctionV2.invoke()`

```
// StarRocksDynamicSinkFunctionV2.java:124-177
public void invoke(T value, Context context) throws Exception {
    // 1. 数据序列化
    String serializedValue = serializer.serialize(
        rowTransformer.transform(value, sinkOptions.supportUpsertDelete()));
    // 2. 写入 Manager
    sinkManager.write(null, database, table, serializedValue);
}
```

缓存写入：`DefaultStreamLoadManager.write()` → `TransactionTableRegion.write()`

```
// DefaultStreamLoadManager.java:260-299
public void write(String uniqueKey, String database, String table, String... rows) {
    TableRegion region = getCacheRegion(uniqueKey, database, table);
    for (String row : rows) {
        int bytes = region.write(row.getBytes(StandardCharsets.UTF_8));
        long cachedBytes = currentCacheBytes.addAndGet(bytes);
        // 背压：总缓存 >= 2*maxCacheBytes 时阻塞写入线程
        if (cachedBytes >= maxWriteBlockCacheBytes) {
            // ... 等待 flush 释放内存
        }
        // 总缓存 >= maxCacheBytes 时唤醒 manager 线程触发 flush
        else if (cachedBytes >= maxCacheBytes) {
            flushable.signal();
        }
    }
}
```

三级缓存结构：

```
activeChunk (当前接收数据)
    │  Chunk 大小超过 chunkLimit 或行数超过 maxBufferRows
    ▼
inactiveChunks (待发送队列)
    │  flush 时通过 HTTP 发送
    ▼
StarRocks (通过 Transaction Stream Load)
```

- **activeChunk**：当前正在接收数据的 `Chunk`，超过阈值后 `switchChunk()` 移入 `inactiveChunks`
- **inactiveChunks**：`ConcurrentLinkedQueue<Chunk>`，flush 时逐个通过 HTTP 发送到 StarRocks
- **背压机制**：`currentCacheBytes >= 2 * maxCacheBytes` 时阻塞 `write()` 线程

阶段 2：Flush 触发与数据发送¶

Flush 有 **5 种触发条件**：

#	触发方式	来源	FlushReason
1	定时扫描 – region age 超限	Manager 守护线程 `shouldCommit()`	`COMMIT`
2	定时扫描 – 行数达限	Manager 守护线程 `region.shouldFlush()`	`BUFFER_ROWS_REACH_LIMIT`
3	定时扫描 – 总缓存满	Manager 守护线程 `selectFlushRegions()`	`CACHE_FULL`
4	写入触发	`write()` 中缓存超阈值	间接唤醒 Manager
5	**Checkpoint 强制 flush**	`snapshotState()` → `sinkManager.flush()`	`FORCE`

Flush 执行链路：

```
TransactionTableRegion.flush(reason)
    → switchChunk()           // 将 activeChunk 移入 inactiveChunks
    → streamLoad(0)           // 取出 Chunk 发送
        → streamLoader.send(region, delayMs)
            → begin(region)   // 首次 flush 时开启事务
            → sendToSR(region) // HTTP PUT 发送数据
```

事务开启时机（`TransactionStreamLoader.begin()`）：

```
// TransactionStreamLoader.java:117-128
public boolean begin(TableRegion region) {
    if (region.getLabel() == null) {
        // 第一次 flush（或 snapshot 后 label 被清空）→ 生成新 label，开启新事务
        region.setLabel(region.getLabelGenerator().next());
        if (doBegin(region)) {  // HTTP POST /api/transaction/begin
            return true;
        }
    }
    return true;  // 已有 label → 复用同一事务
}
```

> **关键点**：事务在**第一次 flush 发送数据时**通过 *`begin()`* 开启，**不是** Checkpoint 时才开启。同一个事务（同一个 label）内可以多次 *`send`* 不同的 Chunk。

数据发送（`DefaultStreamLoader.sendToSR()`）：

```
// DefaultStreamLoader.java:283-361
protected StreamLoadResponse sendToSR(TableRegion region) {
    String sendUrl = getSendUrl(host, region.getDatabase(), region.getTable());
    // 事务模式下：/api/transaction/load
    // 非事务模式：/api/{db}/{table}/_stream_load
    HttpPut httpPut = new HttpPut(sendUrl);
    httpPut.setEntity(region.getHttpEntity());  // Chunk 数据
    // ... 执行 HTTP 请求
    region.complete(streamLoadResponse);  // 成功回调
}
```

发送完成回调（`TransactionTableRegion.complete()`）：

```
// TransactionTableRegion.java:378-398
public void complete(StreamLoadResponse response) {
    Chunk chunk = inactiveChunks.remove();       // 移除已发送的 Chunk
    cacheBytes.addAndGet(-chunk.rowBytes());      // 更新缓存统计
    if (!inactiveChunks.isEmpty()) {
        streamLoad(0);                            // 还有数据，继续发送
        return;
    }
    state.compareAndSet(State.FLUSHING, State.ACTIVE);  // 全部发完，回到 ACTIVE
}
```

阶段 3：Checkpoint 触发（snapshotState）¶

当 Flink Checkpoint Barrier 到达时，触发 `snapshotState()`：

```
// StarRocksDynamicSinkFunctionV2.java:265-288
public void snapshotState(FunctionSnapshotContext ctx) throws Exception {
    // Step 1: 强制 flush 所有缓存数据到 StarRocks
    sinkManager.flush();

    if (sinkOptions.getSemantic() != StarRocksSinkSemantic.EXACTLY_ONCE) {
        return;
    }

    // Step 2: 快照 - 记录所有 Region 的 label，然后清空 label
    StreamLoadSnapshot snapshot = sinkManager.snapshot();

    // Step 3: Prepare - 两阶段提交第一阶段
    if (sinkManager.prepare(snapshot)) {
        // Step 4: 保存到 Flink State Backend
        snapshotMap.put(ctx.getCheckpointId(), Collections.singletonList(snapshot));
        snapshotStates.clear();
        snapshotStates.add(StarrocksSnapshotState.of(snapshotMap, labelSnapshots));
    } else {
        // Prepare 失败 → rollback
        sinkManager.abort(snapshot);
        throw new RuntimeException("Snapshot state failed by prepare");
    }
}
```

`snapshot()` 做了什么：

```
// DefaultStreamLoadManager.java:446-452
public StreamLoadSnapshot snapshot() {
    // 收集所有 region 的 (database, table, label)
    StreamLoadSnapshot snapshot = StreamLoadSnapshot.snapshot(regions.values());
    // 清空所有 region 的 label → 下次 flush 会开启新事务
    for (TableRegion region : regions.values()) {
        region.setLabel(null);
    }
    return snapshot;
}
```

`prepare()` 向 StarRocks 发送 HTTP 请求：

```
// TransactionStreamLoader.java:187-255
public boolean prepare(StreamLoadSnapshot.Transaction transaction) {
    String prepareUrl = getPrepareUrl(host);
    HttpPost httpPost = new HttpPost(prepareUrl);  // /api/transaction/prepare
    httpPost.addHeader("label", transaction.getLabel());
    httpPost.addHeader("db", transaction.getDatabase());
    // ... 发送请求，检查返回状态
}
```

> Prepare 成功后，事务进入 **PREPARED** 状态，数据已持久化但对查询**不可见**。

阶段 4：Checkpoint 完成 → Commit¶

当 Flink Checkpoint 完成时，`notifyCheckpointComplete()` 被调用：

```
// StarRocksDynamicSinkFunctionV2.java:343-377
public void notifyCheckpointComplete(long checkpointId) throws Exception {
    if (sinkOptions.getSemantic() != StarRocksSinkSemantic.EXACTLY_ONCE) {
        return;
    }

    // 找出所有 <= checkpointId 的快照
    List<Long> commitCheckpointIds = snapshotMap.keySet().stream()
            .filter(cpId -> cpId <= checkpointId)
            .sorted(Long::compare)
            .collect(Collectors.toList());

    for (Long cpId : commitCheckpointIds) {
        for (StreamLoadSnapshot snapshot : snapshotMap.get(cpId)) {
            // 对每个事务执行 commit
            if (!sinkManager.commit(snapshot)) {
                throw new RuntimeException("Failed to commit for snapshot " + cpId);
            }
        }
        snapshotMap.remove(cpId);  // 提交成功，移除快照
    }
}
```

`commit()` 向 StarRocks 发送 HTTP 请求：

```
// TransactionStreamLoader.java:258-333
public boolean commit(StreamLoadSnapshot.Transaction transaction) {
    String commitUrl = getCommitUrl(host);
    HttpPost httpPost = new HttpPost(commitUrl);  // /api/transaction/commit
    httpPost.addHeader("label", transaction.getLabel());
    // ... 发送请求
    // 如果返回非 OK，还会通过 getLabelState() 二次确认
    // 处理 FE leader 切换等边界情况
}
```

> Commit 成功后，**数据正式对 StarRocks 查询可见**。

阶段 5：异常处理与恢复¶

5.1 任务关闭 / 失败时（`close()`）¶

```
// StarRocksDynamicSinkFunctionV2.java:250-262
public void close() {
    try {
        sinkManager.flush();                      // 尝试 flush 剩余数据
    } catch (Exception e) {
        log.error("Failed to flush when closing", e);
    } finally {
        StreamLoadSnapshot snapshot = sinkManager.snapshot();
        sinkManager.abort(snapshot);              // rollback 所有未提交事务
        sinkManager.close();
    }
}
```

5.2 任务恢复启动时¶

```
// StarRocksDynamicSinkFunctionV2.java:220-234
private void openForExactlyOnce() throws Exception {
    // 1. 清理残留事务
    if (sinkOptions.isAbortLingeringTxns()) {
        LingeringTransactionAborter aborter = new LingeringTransactionAborter(
                sinkOptions.getLabelPrefix(),
                restoredCheckpointId,
                subtaskIndex,
                checkNumTxns,
                dbTables,
                restoredGeneratorSnapshots,
                sinkManager.getStreamLoader());
        aborter.execute();  // abort PREPARE/PREPARED 状态的残留事务
    }

    // 2. 提交上次已 prepare 但未 commit 的事务
    notifyCheckpointComplete(Long.MAX_VALUE);
}
```

`LingeringTransactionAborter` 的工作原理：

1. 根据恢复的 label snapshot，从 `nextId` 开始逐个检查可能残留的事务
2. 对处于 `PREPARE` / `PREPARED` 状态的事务执行 `rollback()`
3. 如果 `currentLabelPrefix` 与快照中的不同（说明 job 可能在首次 Checkpoint 前就失败了），还会尝试 abort 当前 prefix 下的残留事务
4. 对于已 `COMMITTED` / `VISIBLE` 的事务，抛出异常（说明在从更早的 Checkpoint 恢复，需要更换 label-prefix）

4. 时序图（Exactly-Once 完整流程）¶

```
sequenceDiagram
    participant App as Flink Record
    participant Sink as SinkFunctionV2
    participant Mgr as DefaultStreamLoadManager
    participant Region as TransactionTableRegion
    participant Loader as TransactionStreamLoader
    participant SR as StarRocks BE
    participant State as Flink State

    Note over App, SR: ====== 阶段1 & 2：数据接收、缓存、Flush ======

    App->>Sink: invoke(record)
    Sink->>Mgr: write(db, table, row)
    Mgr->>Region: write(bytes) → activeChunk

    Note over Region: Chunk 满时 switchChunk()

    Region->>Region: flush(reason) → inactiveChunks

    Region->>Loader: send(region)
    Loader->>SR: POST /api/transaction/begin (首次)
    SR-->>Loader: OK (label绑定)
    Loader->>SR: PUT /api/transaction/load (Chunk数据)
    SR-->>Loader: OK
    Loader->>Region: complete() → 继续发下一个Chunk

    Note over App, SR: ====== 阶段3：Checkpoint 触发 ======

    Sink->>Mgr: flush() [强制flush所有缓存]
    Mgr->>Region: flush(FORCE)
    Region->>Loader: send(region) [发送剩余数据]
    Loader->>SR: PUT /api/transaction/load

    Sink->>Mgr: snapshot() [记录labels, 清空region label]
    Sink->>Mgr: prepare(snapshot)
    Mgr->>Loader: prepare(transaction)
    Loader->>SR: POST /api/transaction/prepare
    SR-->>Loader: OK (PREPARED)

    Sink->>State: snapshotStates.add(snapshot)

    Note over App, SR: ====== 阶段4：Checkpoint 完成 ======

    State-->>Sink: notifyCheckpointComplete(cpId)
    Sink->>Mgr: commit(snapshot)
    Mgr->>Loader: commit(transaction)
    Loader->>SR: POST /api/transaction/commit
    SR-->>Loader: OK (VISIBLE) ✓ 数据可见

    Note over App, SR: ====== 阶段5：异常恢复 ======

    Note over Sink: 任务失败重启
    Sink->>State: initializeState() [恢复snapshotMap]
    Sink->>Loader: LingeringTransactionAborter.execute()
    Loader->>SR: rollback 残留 PREPARE/PREPARED 事务
    Sink->>Mgr: commit(恢复的snapshot) [提交已prepare的事务]
    Mgr->>Loader: commit(transaction)
    Loader->>SR: POST /api/transaction/commit
```

5. V2 Sink API 对比¶

Flink 新版 Sink API（`Sink2`）中，职责分离更清晰：

阶段	V1（SinkFunction）	V2（TwoPhaseCommittingSink）
数据写入	`invoke()` → `sinkManager.write()`	`StarRocksWriter.write()` → `sinkManager.write()`
Flush	`snapshotState()` → `sinkManager.flush()`	`StarRocksWriter.flush()` → `sinkManager.flush()`
Prepare	`snapshotState()` → `sinkManager.prepare()`	`StarRocksWriter.prepareCommit()` → `sinkManager.prepare()`
Commit	`notifyCheckpointComplete()` → `sinkManager.commit()`	**`StarRocksCommitter.commit()`** → `sinkManager.commit()`
State	`snapshotState()` 保存到 ListState	`StarRocksWriter.snapshotState()` 返回 WriterState
Abort	`close()` → `sinkManager.abort()`	`StarRocksWriter.close()` → `sinkManager.abort()`

V2 的核心区别：**Commit 由独立的 `StarRocksCommitter` 执行**，与 Writer 解耦，可以在不同的线程/进程中运行。

```
// StarRocksWriter.java:157-169 - prepareCommit
public Collection<StarRocksCommittable> prepareCommit() {
    StreamLoadSnapshot snapshot = sinkManager.snapshot();
    if (sinkManager.prepare(snapshot)) {
        return Collections.singleton(new StarRocksCommittable(snapshot));
    } else {
        sinkManager.abort(snapshot);
        throw new RuntimeException("Snapshot state failed by prepare");
    }
}

// StarRocksCommitter.java:64-87 - commit（独立组件）
public void commit(Collection<CommitRequest<StarRocksCommittable>> committables) {
    for (CommitRequest<StarRocksCommittable> commitRequest : committables) {
        StarRocksCommittable committable = commitRequest.getCommittable();
        // 带重试的 commit
        for (int i = 0; i <= maxRetries; i++) {
            boolean success = sinkManager.commit(committable.getLabelSnapshot());
            if (success) break;
        }
    }
}
```

6. 事务生命周期总结¶

6.1 各场景 Commit / Rollback 决策¶

场景	谁决定 Commit	谁决定 Rollback
Exactly-Once	`notifyCheckpointComplete()` — Checkpoint 成功后 commit	`snapshotState()` prepare 失败时 abort；`close()` 时 abort 未完成事务
At-Least-Once	`TransactionTableRegion.doCommit()` — flush 完直接 prepare+commit	`fail()` 回调触发重试，超出重试次数后上报异常
恢复时残留事务	`notifyCheckpointComplete(MAX)` 提交已 prepare 的事务	`LingeringTransactionAborter` 启动时 abort PREPARE/PREPARED 状态事务

6.2 事务状态流转¶

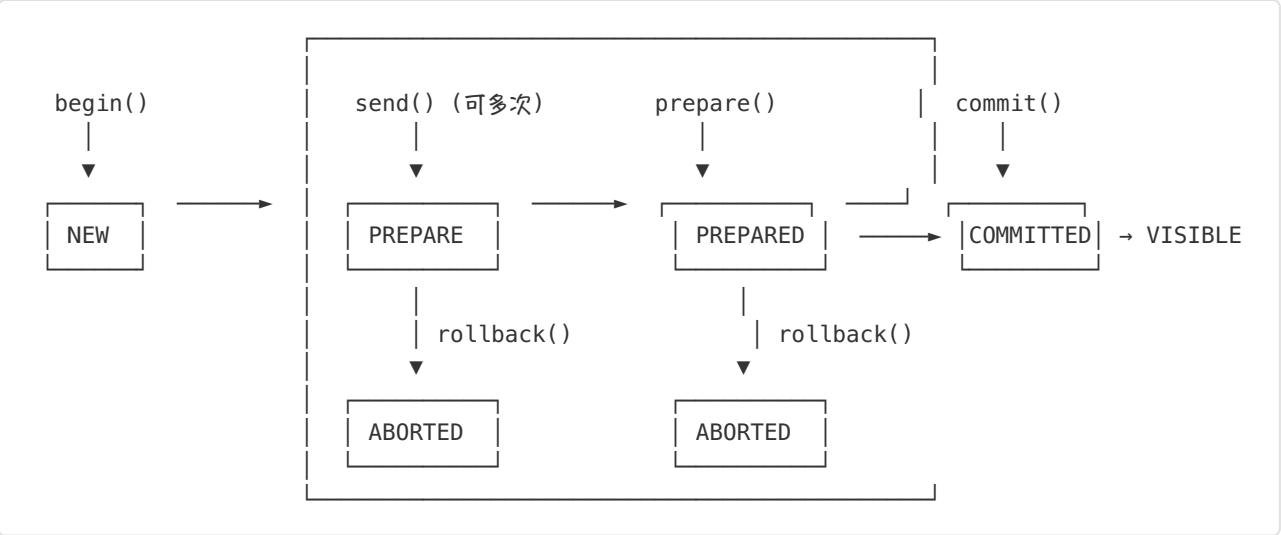

6.3 Flush 触发条件总结¶

#	触发条件	来源	FlushReason
1	Region age 超过 `expectDelayTime/scanningFrequency`	Manager 守护线程定时扫描	`COMMIT`
2	Region 行数 >= `maxBufferRows`	Manager 守护线程定时扫描	`BUFFER_ROWS_REACH_LIMIT`
3	总缓存 >= `maxCacheBytes`	Manager 守护线程定时扫描	`CACHE_FULL`（选最大 region）
4	总缓存 >= `maxCacheBytes`	`write()` 中唤醒 Manager	间接触发
5	Checkpoint Barrier 到达	`snapshotState()` → `flush()`	`FORCE`

---

7. 常见误区¶

❌ 误区："Checkpoint 时间到了，才开启 StarRocks 的事务"¶

正确理解：

事务在 **flush 发送数据时就已经开启了**（通过 `TransactionStreamLoader.begin()`），而不是等到 Checkpoint 触发时才开启。

在两次 Checkpoint 之间，数据可能已经通过多次 flush 发送到 StarRocks，且这些 flush 共享同一个事务（同一个 label）。Checkpoint 到来时执行的是 **prepare**（两阶段提交的第一阶段），而非 begin。

完整时间线：

```
数据到达 → 写入缓存 → 缓存满触发 flush → begin 事务 → send 数据
                                  |
更多数据到达 → 继续写缓存 → 又触发 flush → send 数据（复用同一事务）
                                  |
 Checkpoint Barrier → 强制 flush → send 剩余数据 → prepare 事务
                                  |
 Checkpoint 成功 ──────────────→ commit 事务（数据可见）
```

❌ 误区："每次 flush 都会开启一个新事务"¶

正确理解：

同一个 Checkpoint 周期内，同一个表的所有 flush 共享同一个事务。只有在 `snapshot()` 之后（label 被清空），下一次 flush 才会通过 `begin()` 开启新事务。

❌ 误区："Checkpoint 失败会触发 rollback"¶

正确理解：

该 Connector **没有实现** `notifyCheckpointAborted()`。Checkpoint 失败通常导致 Flink 任务 failover，在 `close()` 中执行 abort。恢复时由 `LingeringTransactionAborter` 清理残留事务。

---

8. 关键代码文件索引¶

文件	职责
`src/.../table/sink/StarRocksDynamicSinkFunctionV2.java`	Flink SinkFunction 入口，Checkpoint 协调
`starrocks-stream-load-sdk/.../v2/DefaultStreamLoadManager.java`	核心 Manager，管理缓存、flush、事务
`starrocks-stream-load-sdk/.../v2/StreamLoadManagerV2.java`	Manager 代理层
`starrocks-stream-load-sdk/.../v2/TransactionTableRegion.java`	表级缓存区，三级缓存管理
`starrocks-stream-load-sdk/.../TransactionStreamLoader.java`	事务 HTTP 操作：begin/send/prepare/commit/rollback
`starrocks-stream-load-sdk/.../DefaultStreamLoader.java`	基础 StreamLoader，HTTP 发送实现
`starrocks-stream-load-sdk/.../v2/FlushAndCommitStrategy.java`	Flush/Commit 策略决策
`starrocks-stream-load-sdk/.../v2/FlushReason.java`	Flush 原因枚举
`starrocks-stream-load-sdk/.../StreamLoadSnapshot.java`	快照数据结构（label 列表）
`src/.../table/sink/LingeringTransactionAborter.java`	恢复时清理残留事务
`src/.../table/sink/v2/StarRocksWriter.java`	V2 Sink API Writer
`src/.../table/sink/v2/StarRocksCommitter.java`	V2 Sink API 独立 Committer

> **总结**：Flink 写 StarRocks 的核心是 **Transaction Stream Load + Flink Checkpoint 两阶段提交**。数据先缓存在本地 Chunk 中，flush 时开启事务并发送数据，Checkpoint 时 prepare 锁定事务并持久化 label 到 State，Checkpoint 成功后 commit 使数据可见。整个机制通过 Flink Checkpoint 保证了端到端的 Exactly-Once 语义。